Московский государственный технический университет им. Н.Э. Баумана

Отчёт по лабораторной работе №6 по курсу «Технологии машинного обучения».

«Анализ и прогнозирование временного ряда».

Выполнил:
Анцифров Н. С.
студент группы ИУ5-61Б

Проверил:
Гапанюк Ю.Е.

Подпись и дата:

Подпись и дата:

Москва, 2022 г.

1. Задание лабораторной работы

- Выбрать набор данных (датасет) для решения задачи прогнозирования временного ряда.
- Визуализировать временной ряд и его основные характеристики.
- Разделить временной ряд на обучающую и тестовую выборку.
- Произвести прогнозирование временного ряда с использованием как минимум двух методов.
- Визуализировать тестовую выборку и каждый из прогнозов.
- Оценить качество прогноза в каждом случае с помощью метрик.

2. Ячейки Jupyter-ноутбука

2.1. Выбор и загрузка данных

2.1.1. Текстовое описание

В качестве датасета для решения задачи прогнозирования временного ряда будем использовать набор данных, содержащий ежедневные климатические данные в городе Дели с 2013 по 2017 год. Данный набор доступен по адресу: https://www.kaggle.com/datasets/sumanthvrao/daily-climate-time-series-data

Набор данных имеет следующие атрибуты:

- date - Дата - метка времени
- meantemp - Средняя температура - средняя температура, расчитанная по нескольким 3-часовым интервалам в день
- humidity - Влажность - показатель влажности в граммах воды на кубический метр воздуха
- wind_speed - Скорость ветра - скорость ветра в километрах в час
- meanpressure - Среднее давление - среднее давление в атмосферах

2.1.2. Импорт библиотек

Импортируем библиотеки с помощью команды import:

[1]:
```
import numpy as np
import pandas as pd
from matplotlib import pyplot
import matplotlib.pyplot as plt
```

Уберем предупреждения:

[2]:
```
import warnings
warnings.filterwarnings('ignore')
```

2.1.3. Загрузка данных

Выборка уже разделена. Для первичного анализа объединим тестовую и обучающую выборку:

[3]:
```
data_test = pd.read_csv('DailyDelhiClimateTest.csv', header=0,
 ↪parse_dates=['date'], index_col='date', squeeze=True)
data_train = pd.read_csv('DailyDelhiClimateTrain.csv', header=0,
 ↪parse_dates=['date'], index_col='date', squeeze=True)
data = pd.concat([data_train, data_test], axis=0)
```

2.2. Первичная обработка данных и визуализация

2.2.1. Первичный анализ

Выведем первые 5 строк датасета:

[4]:
```
data.head()
```

[4]:
```
             meantemp   humidity  wind_speed  meanpressure
date
2013-01-01  10.000000  84.500000    0.000000   1015.666667
2013-01-02   7.400000  92.000000    2.980000   1017.800000
2013-01-03   7.166667  87.000000    4.633333   1018.666667
2013-01-04   8.666667  71.333333    1.233333   1017.166667
2013-01-05   6.000000  86.833333    3.700000   1016.500000
```

Определим размер датасета:

[5]:
```
data.shape
```

[5]:
```
(1576, 4)
```

Определим типы данных:

[6]:
```
data.dtypes
```

[6]:
```
meantemp        float64
humidity        float64
wind_speed      float64
meanpressure    float64
dtype: object
```

2.2.2. Обработка данных

Оставим только столбец влажности для временного ряда:

[7]:
```
data = data.drop(columns=['meantemp'], axis=1)
data = data.drop(columns=['wind_speed'], axis=1)
data = data.drop(columns=['meanpressure'], axis=1)
```

[8]:
```
data.head()
```

[8]:
```
             humidity
date
2013-01-01  84.500000
2013-01-02  92.000000
2013-01-03  87.000000
2013-01-04  71.333333
2013-01-05  86.833333
```

2.2.3. Основные статистические характеристки

Определим основные статистические характеристки временного ряда:

[9]:
```
data.describe()
```

[9]:
```
           humidity
count  1576.000000
mean     60.445229
std      16.979994
min      13.428571
25%      49.750000
50%      62.440476
75%      72.125000
max     100.000000
```

2.2.4. Визуализация исходного временного ряда

В виде графика:

[10]:
```
fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(10,5))
fig.suptitle('Временной ряд в виде графика')
data.plot(ax=ax, legend=False)
pyplot.show()
```

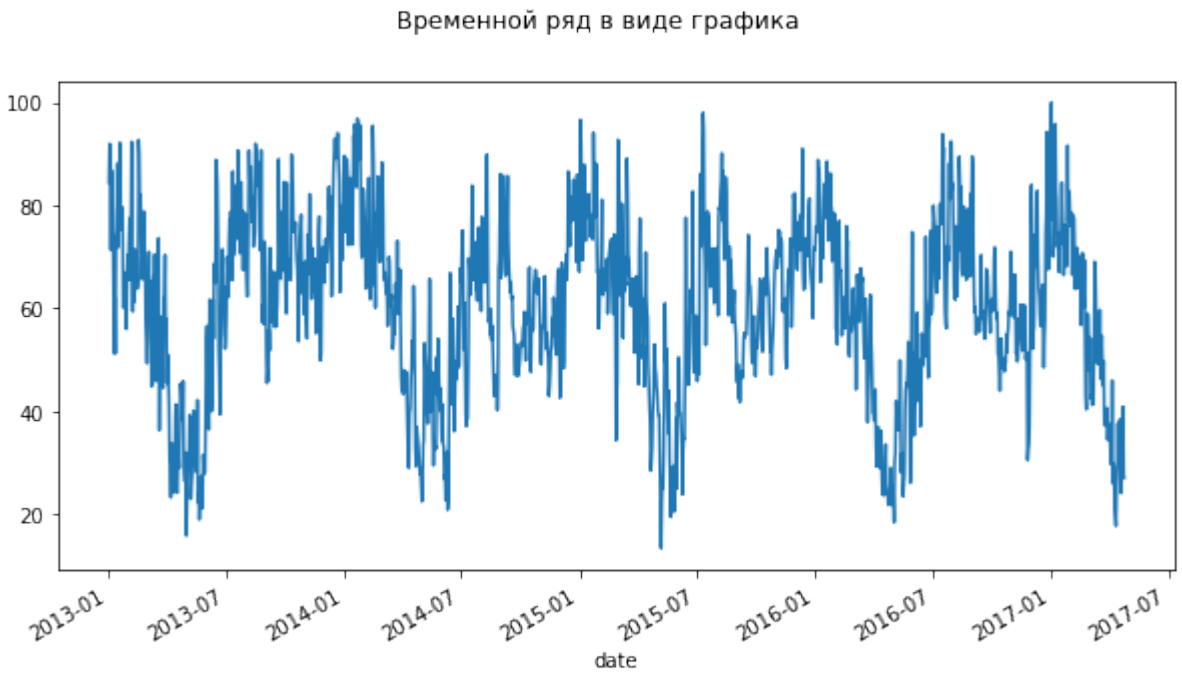

[11]:
```
fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(10,5))
fig.suptitle('Первые 30 точек ряда')
data[:30].plot(ax=ax, legend=False)
pyplot.show()
```

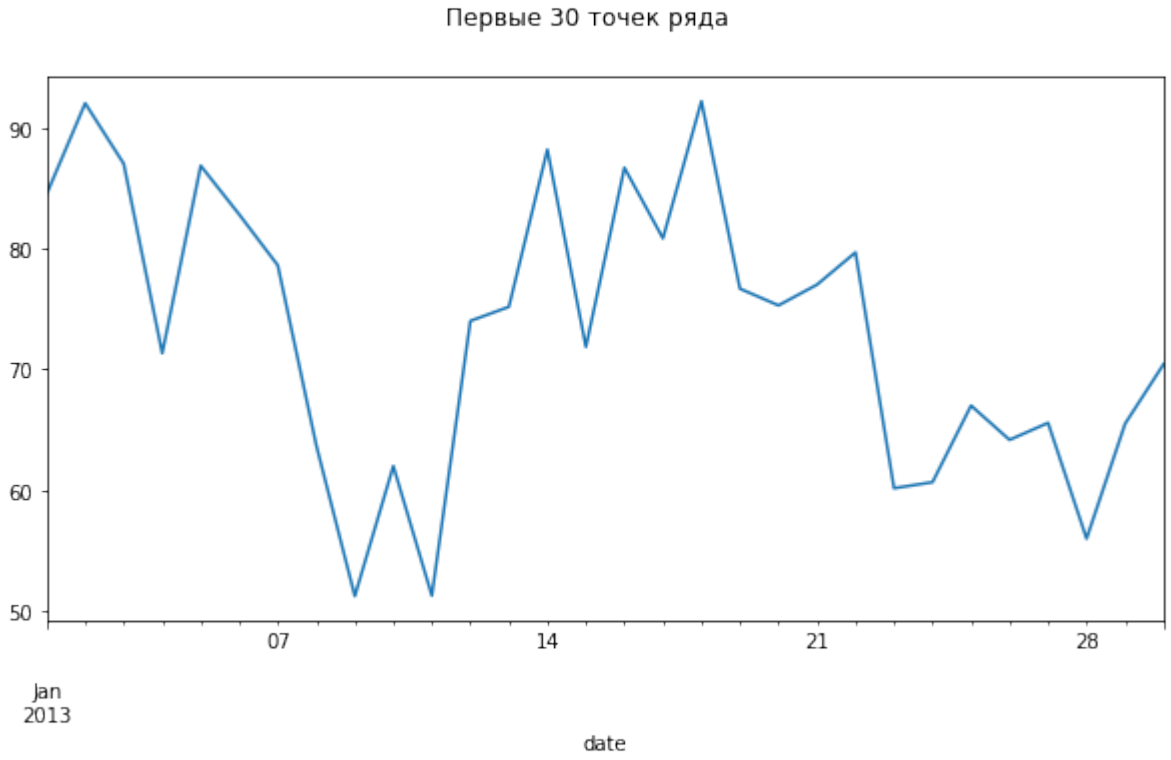

В виде гистограммы:

[12]:
```
fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(10,5))
fig.suptitle('Гистограмма')
data.hist(ax=ax, legend=False)
pyplot.show()
```

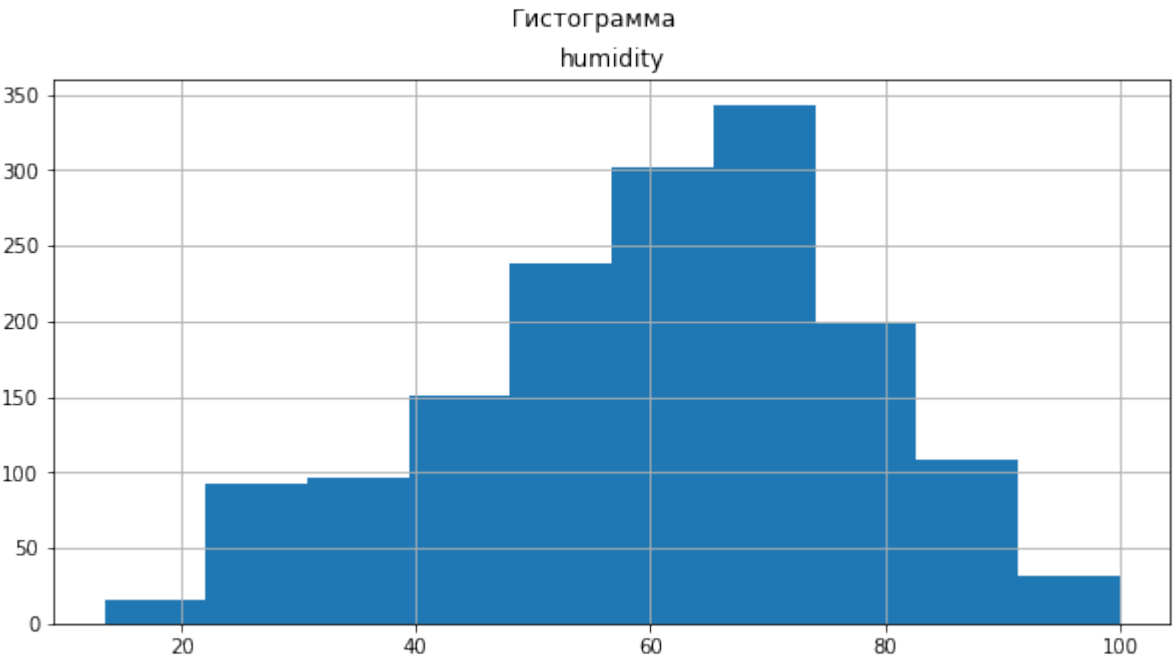

Вероятностная плотность распределения данных:

[13]:
```
fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(10,5))
fig.suptitle('Плотность вероятности распределения данных')
data.plot(ax=ax, kind='kde', legend=False)
pyplot.show()
```

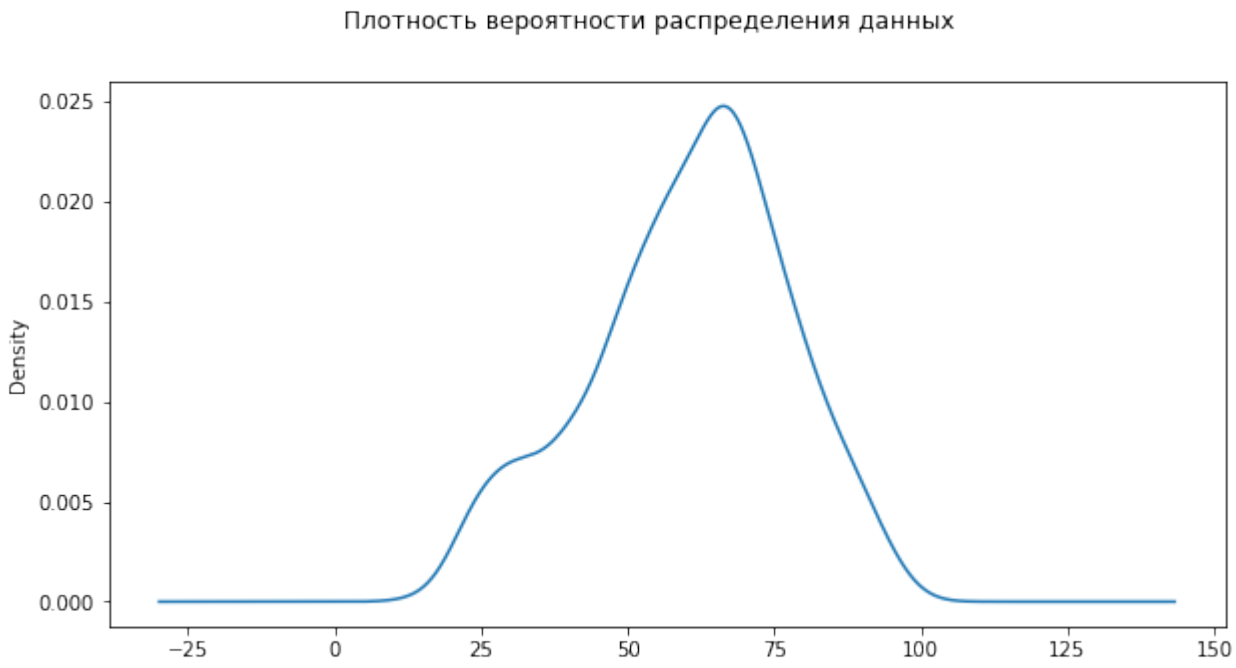

С помощью Lag Plot:

[14]:
```
for i in range(1, 5):
    fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(5,5))
    fig.suptitle(f'Лаг порядка {i}')
    pd.plotting.lag_plot(data, lag=i, ax=ax)
    pyplot.show()
```

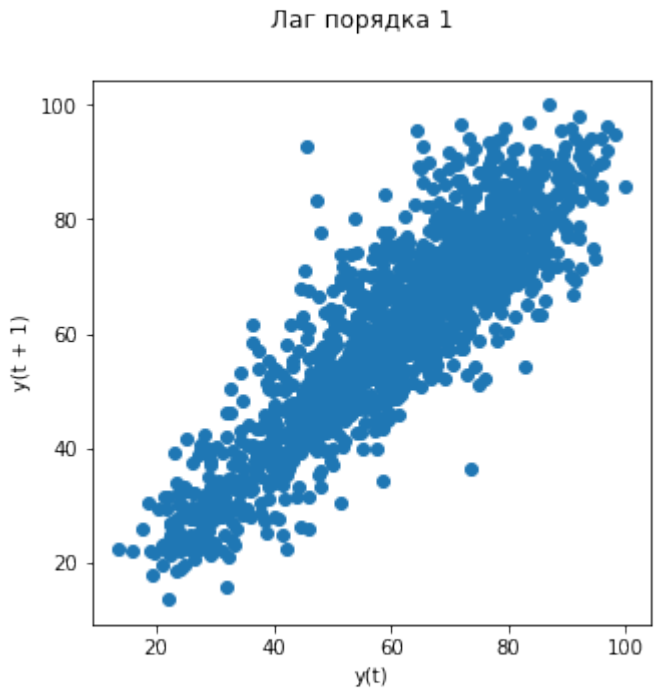

Лаг порядка 2

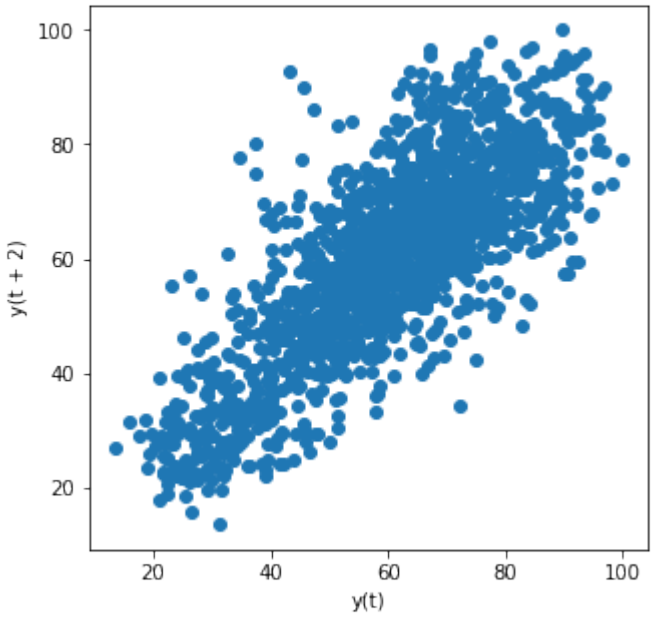

Лаг порядка 3

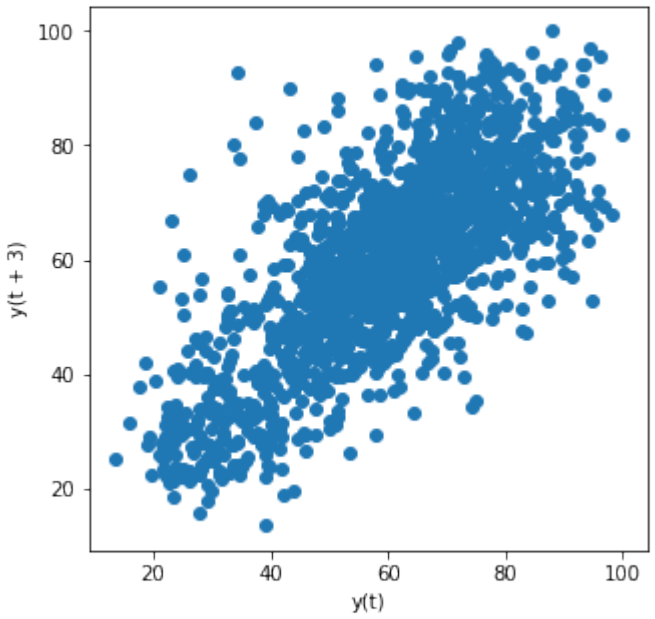

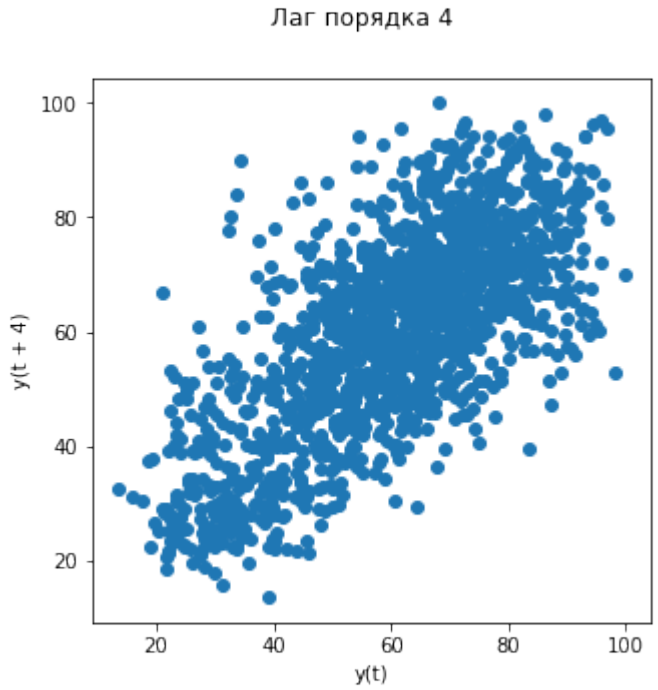

Наблюдается достаточно сильная положительная корреляция.
Автокорреляционная диаграмма:

[15]:
```
fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(10,5))
fig.suptitle('Автокорреляционная диаграмма')
pd.plotting.autocorrelation_plot(data, ax=ax)
pyplot.show()
```

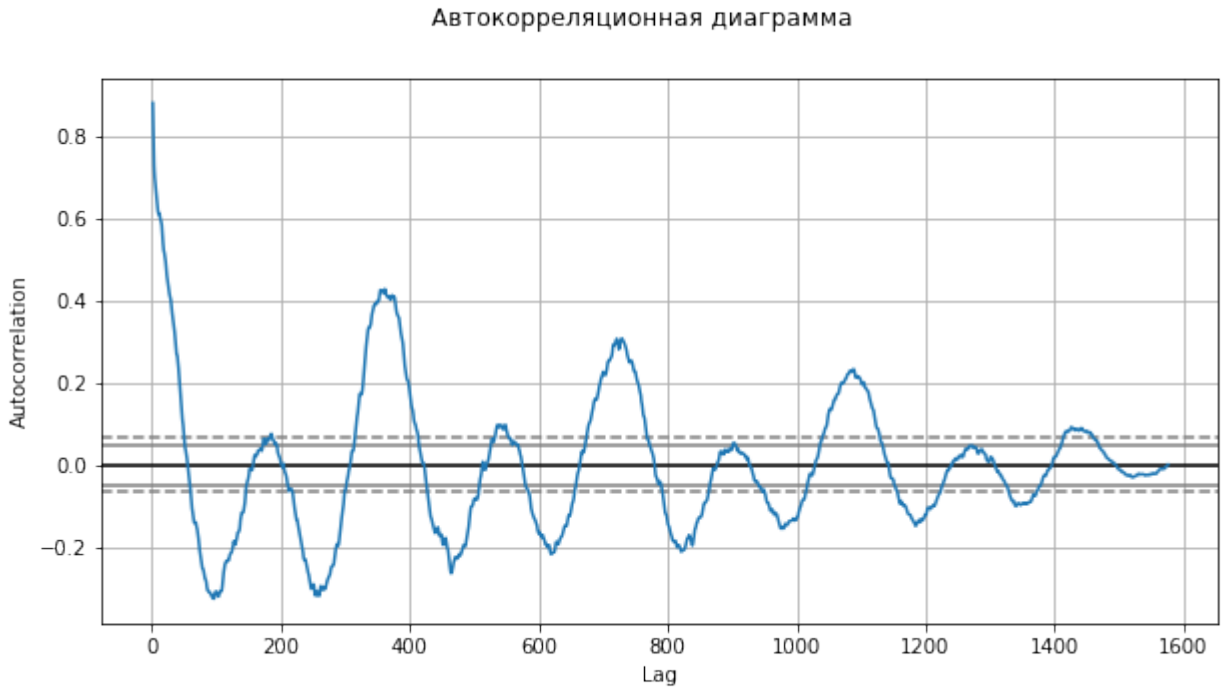

Автокорреляционная функция:

[16]:
```
from statsmodels.graphics.tsaplots import plot_acf
plot_acf(data, lags=30)
plt.tight_layout()
```

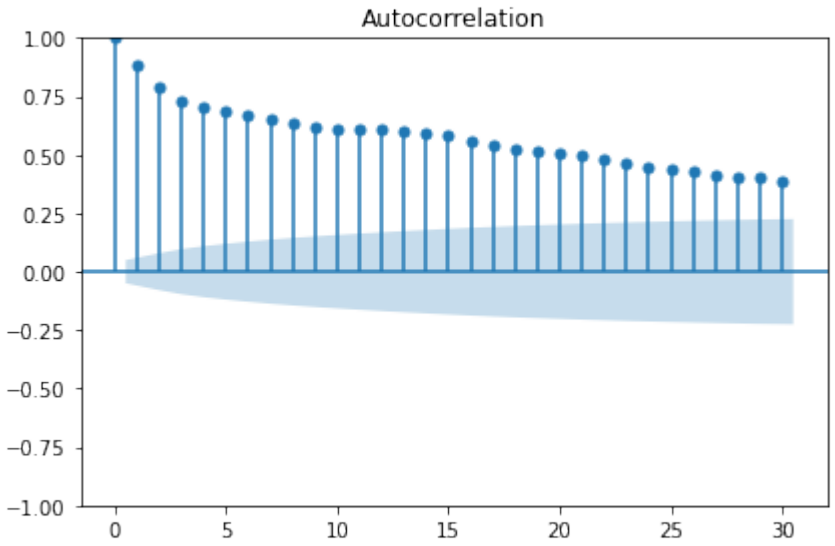

Частичная автокорреляционная функция:

[17]:
```
from statsmodels.graphics.tsaplots import plot_pacf
plot_pacf(data, lags=30)
plt.tight_layout()
```

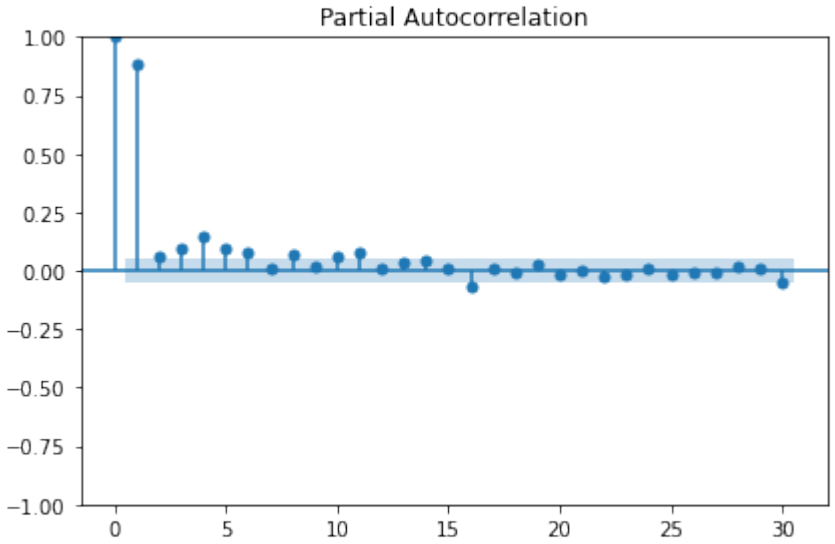

Временной ряд со скользящими средними:

[18]:
```
data2 = data.copy()
```

[19]:
```
data2['SMA_10'] = data2['humidity'].rolling(10, min_periods=1).mean()
data2['SMA_20'] = data2['humidity'].rolling(20, min_periods=1).mean()
```

[20]:
```
fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(10,5))
fig.suptitle('Временной ряд со скользящими средними')
data2[:100].plot(ax=ax, legend=True)
pyplot.show()
```

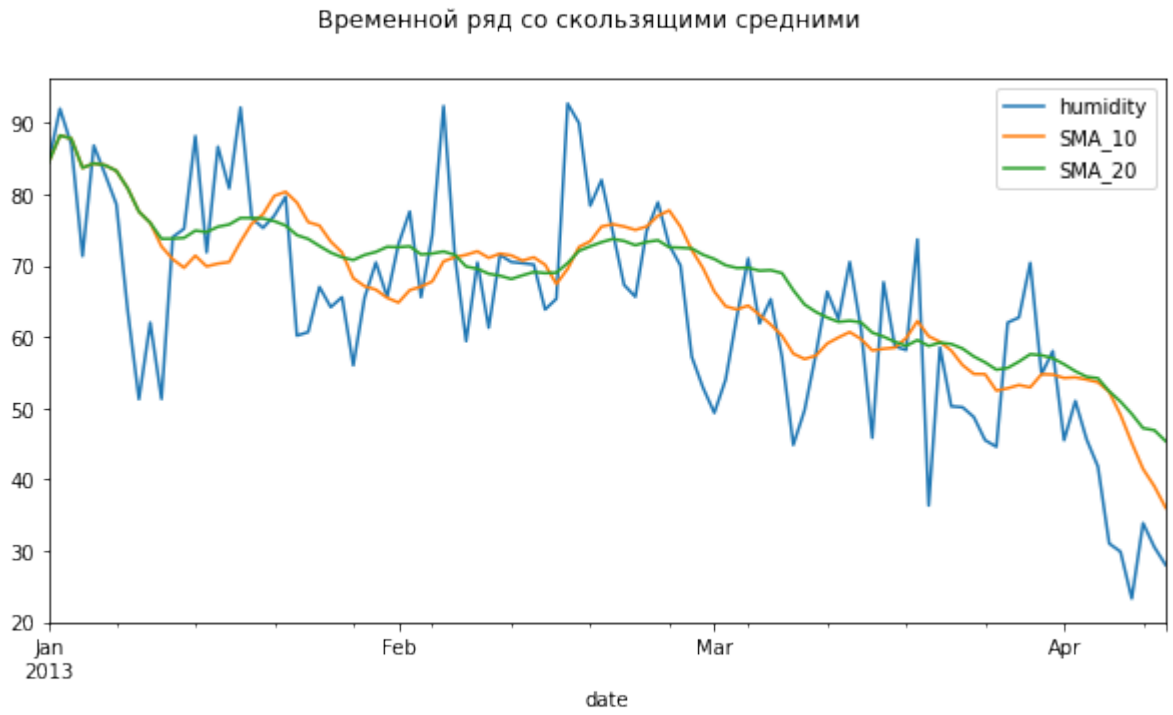

2.3. Прогнозирование временного ряда с использованием авторегрессионного метода

Будем использовать авторегриссионный метод ARIMA:

[21]:
```
from statsmodels.tsa.arima.model import ARIMA
```

2.3.1. Разделение выборки на обучающую и тестовую

[22]:
```
xnum = list(range(data2.shape[0]))
Y = data2['humidity'].values
train_size = int(len(Y) * 0.7)
xnum_train, xnum_test = xnum[0:train_size], xnum[train_size:]
train, test = Y[0:train_size], Y[train_size:]
history_arima = [x for x in train]
```

2.3.2. Прогноз ARIMA

[23]:
```
arima_order = (6, 1, 0)
predictions_arima = list()
for t in range(len(test)):
    model_arima = ARIMA(history_arima, order=arima_order)
    model_arima_fit = model_arima.fit()
```

```
    yhat_arima = model_arima_fit.forecast()[0]
    predictions_arima.append(yhat_arima)
    history_arima.append(test[t])
```

[24]:
```
data2['predictions_ARIMA'] = (train_size * [np.NAN]) + list(predictions_arima)
```

2.3.3. Визуализация

[25]:
```
fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(20,10))
fig.suptitle('Предсказания временного ряда')
data2.plot(ax=ax, legend=True)
pyplot.show()
```

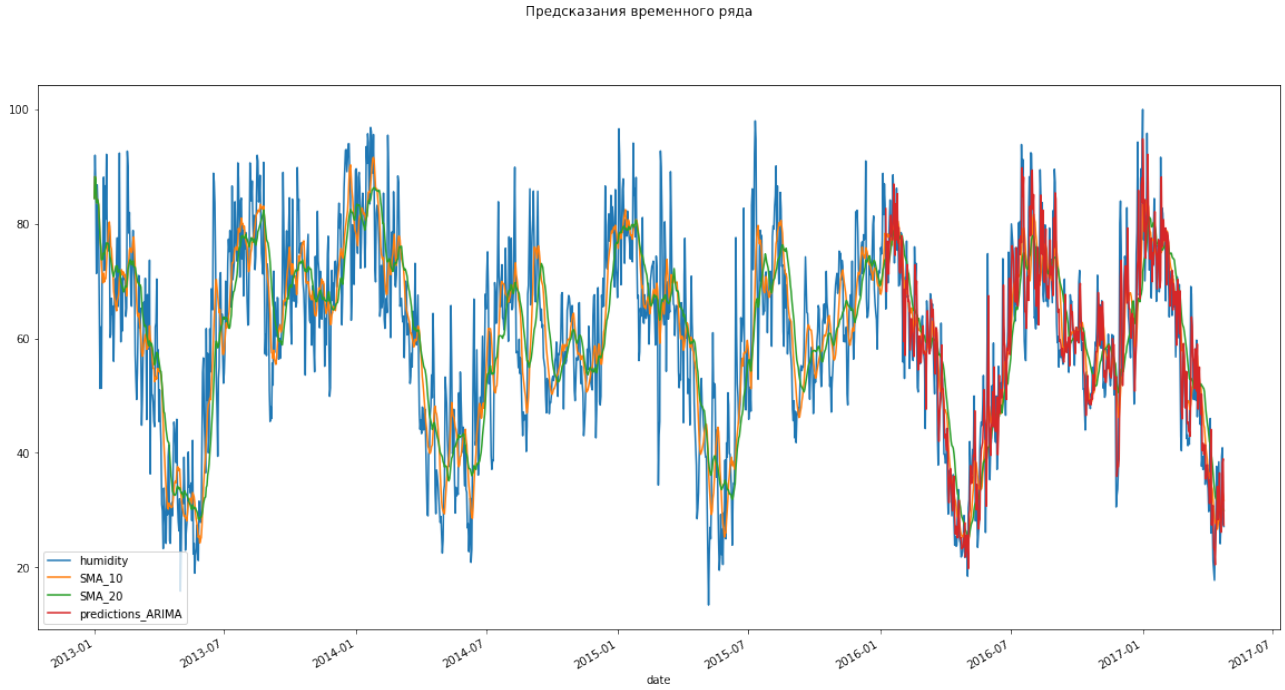

[26]:
```
fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(20,10))
fig.suptitle('Предсказания временного ряда (тестовая выборка)')
data2[train_size:].plot(ax=ax, legend=True)
pyplot.show()
```

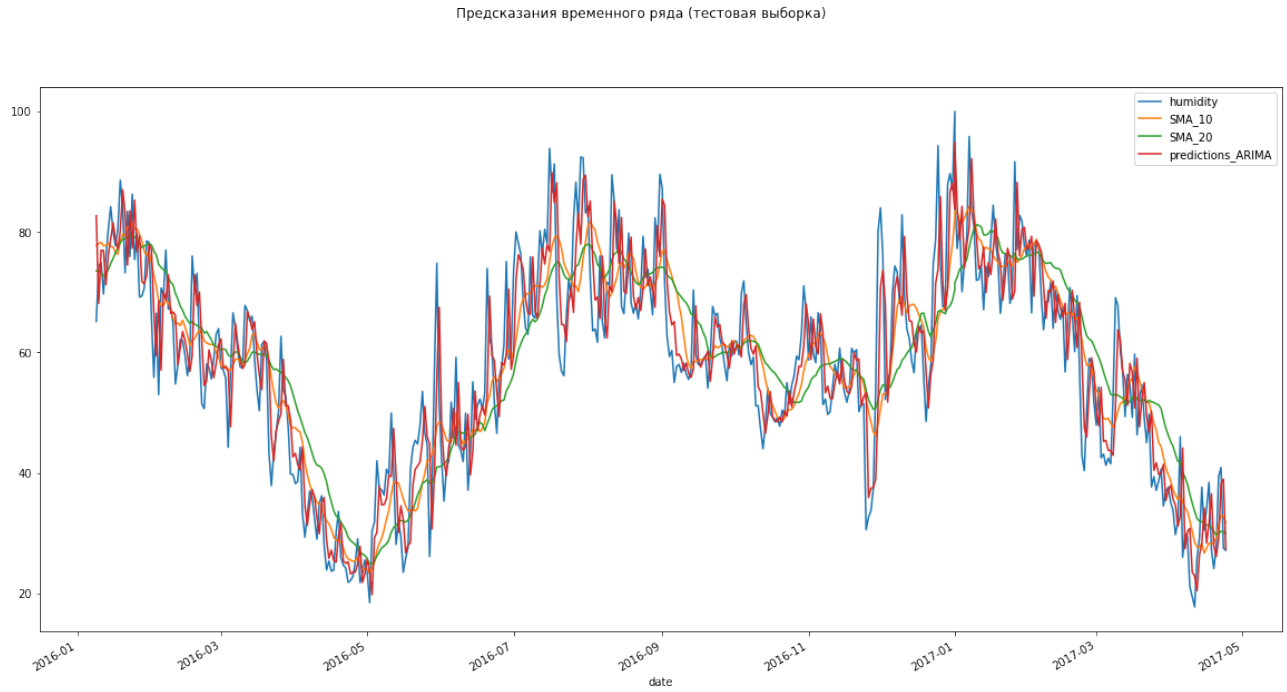

Предсказания ARIMA точны, близки к исходному, далеки от среднего скользящего.

2.3.4. Метрики

MAE и MSE:

[27]:
```
from sklearn.metrics import mean_absolute_error, mean_squared_error
```

[28]:
```
mean_squared_error(test, predictions_arima, squared=False)
```

[28]:
```
7.277480320087945
```

[29]:
```
mean_absolute_error(test, predictions_arima)
```

[29]:
```
5.499332563097871
```

2.4. Прогнозирование временного ряда с использованием метода символьной регрессии

Будем использовать библиотеку gplearn:

[30]:
```
from gplearn.genetic import SymbolicRegressor
```

2.4.1. Прогноз

[31]:
```
function_set = ['add', 'sub', 'mul', 'div', 'sin']
est_gp = SymbolicRegressor(population_size=500, metric='mse',
                           generations=200, stopping_criteria=0.01,
                           init_depth=(4, 10), verbose=1,
 ↪function_set=function_set,
                           const_range=(-10, 10), random_state=0)
```

[32]:
```
est_gp.fit(np.array(xnum_train).reshape(-1, 1), train.reshape(-1, 1))
```

```
    |   Population Average    |             Best Individual              |
---- ------------------------- ------------------------------------------
----------
 Gen   Length          Fitness   Length          Fitness      OOB Fitness  Time
Left
   0   263.65      1.91324e+67       26           3366.8              N/A
6.89m
   1   161.42      1.73488e+15        3           771.22              N/A
3.18m
   2    62.67      3.99717e+14        3           771.22              N/A
1.78m
   3    39.15      3.51722e+10        3            285.6              N/A
1.41m
   4    24.00      3.38638e+11        3            285.6              N/A
1.24m
   5    26.05      6.84991e+09       34           280.86              N/A
1.24m
   6    11.13       1.4874e+10       35          280.438              N/A
1.02m
   7    19.15      4.04141e+06       33          280.136              N/A
1.19m
   8    33.94      2.44637e+10       62          279.776              N/A
1.37m
   9    36.48       2.2103e+06       42           279.19              N/A
1.45m
  10    45.82      1.61747e+09       39          279.026              N/A
1.60m
  11    50.83      1.24868e+06       60          278.728              N/A
1.72m
  12    51.02      1.20327e+06       72          278.686              N/A
1.65m
  13    46.53      5.97296e+08       64          278.507              N/A
1.59m
  14    59.07           988142       67          278.056              N/A
1.74m
  15    80.40       1.4714e+06       70          277.651              N/A
1.95m
  16    91.46      4.15928e+06       58          274.954              N/A
2.14m
  17    94.69      1.16678e+06       58          274.954              N/A
2.24m
  18   131.75      3.04158e+06      113          274.223              N/A
2.68m
  19   154.79           599428       70          267.841              N/A
3.01m
  20   129.60      5.39217e+06      128          267.662              N/A
2.65m
  21   100.25      4.61995e+06       67          263.942              N/A
2.26m
  22    92.04           274173      103          263.402              N/A
2.13m
```

23	107.35	193345	183	258.85	N/A
2.34m					
24	108.87	140414	183	258.017	N/A
2.35m					
25	123.21	185654	212	240.913	N/A
2.52m					
26	180.34	297662	210	240.84	N/A
3.19m					
27	208.77	143690	211	239.988	N/A
3.55m					
28	213.35	338481	299	238.607	N/A
3.60m					
29	222.05	231000	476	238.538	N/A
3.85m					
30	267.90	200555	303	238.41	N/A
4.21m					
31	298.85	110925	556	238.103	N/A
4.54m					
32	309.06	185395	556	238.07	N/A
4.76m					
33	340.90	132016	354	238.051	N/A
5.06m					
34	326.51	129423	332	237.828	N/A
4.87m					
35	314.32	939493	344	237.792	N/A
4.77m					
36	327.52	129602	303	230.187	N/A
4.94m					
37	318.18	7.70537e+07	340	220.34	N/A
4.71m					
38	329.86	157729	366	220.279	N/A
4.92m					
39	330.05	310550	329	219.403	N/A
5.46m					
40	342.88	184113	348	218.34	N/A
5.47m					
41	349.80	1.90276e+09	329	217.718	N/A
5.27m					
42	360.93	303619	327	217.701	N/A
5.24m					
43	344.29	226896	320	210.026	N/A
4.91m					
44	337.52	231055	398	206.541	N/A
4.91m					
45	340.60	294015	398	206.541	N/A
4.94m					
46	359.81	256564	407	195.67	N/A
5.08m					
47	407.65	152362	493	193.514	N/A
5.65m					
48	424.48	5.85872e+06	450	190.798	N/A
5.74m					
49	464.99	356433	450	190.793	N/A

6.15m					
50	479.00	2.61636e+06	469	189.585	N/A
6.23m					
51	463.20	97706.7	574	181.247	N/A
5.96m					
52	486.36	314938	641	180.519	N/A
6.18m					
53	533.12	319413	582	180.251	N/A
6.65m					
54	599.20	154258	580	179.739	N/A
7.33m					
55	605.87	115203	780	179.665	N/A
7.32m					
56	607.26	1.10202e+06	580	161.751	N/A
7.30m					
57	590.25	325810	607	157.107	N/A
7.11m					
58	599.51	175627	498	154.816	N/A
7.55m					
59	615.73	2.05937e+07	585	147.345	N/A
7.40m					
60	572.38	381544	597	146.883	N/A
6.80m					
61	576.44	289927	509	145.037	N/A
6.85m					
62	557.31	243327	651	144.194	N/A
6.49m					
63	574.89	2.80685e+06	579	142.065	N/A
6.70m					
64	595.33	217064	582	140.262	N/A
6.93m					
65	592.78	112236	578	139.268	N/A
7.19m					
66	601.12	214792	687	139.167	N/A
6.90m					
67	596.97	401058	580	138.77	N/A
6.64m					
68	596.88	183980	731	138.407	N/A
6.66m					
69	605.00	196923	645	138.124	N/A
6.63m					
70	624.28	120101	702	134.96	N/A
6.68m					
71	613.74	65220.9	700	134.95	N/A
6.54m					
72	662.45	219994	706	134.663	N/A
6.93m					
73	713.11	84137	720	134.383	N/A
8.34m					
74	706.18	145495	708	134.371	N/A
8.62m					
75	691.32	164370	734	133.882	N/A
7.93m					

76	714.10	112927	859	133.105	N/A
7.28m					
77	741.06	81064	920	132.395	N/A
7.66m					
78	804.12	234355	1049	132.429	N/A
7.90m					
79	822.98	90264.5	869	131.907	N/A
8.02m					
80	832.85	205834	942	131.6	N/A
8.21m					
81	860.39	295080	983	131.305	N/A
9.52m					
82	891.89	244599	891	130.529	N/A
8.71m					
83	941.01	236574	1051	130.064	N/A
8.72m					
84	945.35	5.90819e+08	1051	129.819	N/A
8.33m					
85	942.77	93379.8	1049	129.519	N/A
8.01m					
86	983.41	235777	995	126.097	N/A
8.39m					
87	1043.72	581588	999	125.898	N/A
9.05m					
88	1142.51	286982	1005	124.618	N/A
9.94m					
89	1031.67	108799	989	123.27	N/A
8.37m					
90	1074.67	128401	981	123.027	N/A
8.70m					
91	1026.87	5.90862e+08	987	121.965	N/A
8.54m					
92	1003.39	2.34917e+09	1274	121.202	N/A
8.24m					
93	1012.57	201797	982	120.63	N/A
8.29m					
94	1065.47	128891	974	120.402	N/A
8.60m					
95	1066.71	251783	1023	120.04	N/A
8.50m					
96	1003.03	202755	1037	119.958	N/A
8.05m					
97	981.58	159988	1001	119.906	N/A
8.11m					
98	993.94	322564	989	119.464	N/A
7.99m					
99	991.74	187031	946	119.374	N/A
7.32m					
100	993.97	105857	1142	119.102	N/A
7.14m					
101	976.85	79860.2	1144	119.079	N/A
7.14m					
102	995.50	221920	951	118.929	N/A

7.40m
 103 938.70 90457.6 950 118.854 N/A
6.86m
 104 937.47 314656 939 118.68 N/A
6.62m
 105 936.34 149304 919 118.526 N/A
6.47m
 106 937.20 2.00517e+07 923 118.466 N/A
6.38m
 107 941.85 8.91926e+09 1041 117.759 N/A
6.61m
 108 943.66 159067 1041 117.646 N/A
6.67m
 109 968.74 94109 1041 117.582 N/A
6.73m
 110 1048.24 75924.5 1136 117.307 N/A
7.16m
 111 1057.97 1.13477e+06 1180 117.163 N/A
7.35m
 112 1076.84 236939 1182 116.834 N/A
7.29m
 113 1128.41 73033.1 1188 116.809 N/A
7.36m
 114 1120.40 256617 1178 116.745 N/A
7.28m
 115 1142.22 139713 1205 116.588 N/A
7.34m
 116 1161.78 119681 1389 116.536 N/A
7.36m
 117 1177.39 163665 1523 116.336 N/A
7.38m
 118 1174.59 1.49591e+06 1210 116.279 N/A
7.19m
 119 1171.17 164129 1212 116.271 N/A
7.12m
 120 1158.92 37142.5 1389 116.147 N/A
7.51m
 121 1197.40 46742.8 1217 116.097 N/A
7.93m
 122 1216.58 332484 1343 116.026 N/A
7.59m
 123 1203.00 63012.6 1215 115.981 N/A
7.06m
 124 1205.20 217140 1208 115.942 N/A
7.12m
 125 1200.88 195967 1361 115.919 N/A
6.74m
 126 1201.62 36773.3 1213 115.845 N/A
6.31m
 127 1192.41 175546 1436 115.636 N/A
6.46m
 128 1178.73 118886 1436 115.632 N/A
6.20m

129	1228.00	92349.2	1435	115.615	N/A
6.29m					
130	1219.99	177369	1435	115.615	N/A
6.44m					
131	1219.26	581658	1435	115.581	N/A
6.30m					
132	1241.64	5.95807e+08	1338	115.248	N/A
6.27m					
133	1238.89	278341	1361	115.15	N/A
6.16m					
134	1248.58	1.60758e+11	1383	115.108	N/A
6.11m					
135	1302.84	142129	1362	115.062	N/A
6.43m					
136	1327.08	80862	1628	110.496	N/A
6.47m					
137	1368.02	119268	1745	110.206	N/A
6.30m					
138	1492.48	37613.6	1747	109.06	N/A
6.74m					
139	1678.08	26897.3	1753	108.847	N/A
7.39m					
140	1722.07	122838	1936	107.952	N/A
7.45m					
141	1781.41	83720.5	2025	107.852	N/A
7.60m					
142	1842.02	48335.6	1971	107.611	N/A
7.75m					
143	1947.55	82681.7	1964	107.512	N/A
7.94m					
144	1933.71	6.0061e+08	1970	107.395	N/A
7.95m					
145	1972.54	74686.6	1970	106.999	N/A
8.15m					
146	1954.03	64469.6	2011	106.981	N/A
6.84m					
147	1951.31	8795.11	1942	106.773	N/A
7.37m					
148	1955.85	975.374	1941	106.647	N/A
7.33m					
149	1965.40	3.42713e+06	2020	106.646	N/A
7.20m					
150	1947.16	78761.9	2019	106.512	N/A
7.08m					
151	1933.35	58093.1	2018	106.506	N/A
6.79m					
152	1964.62	57360.7	2004	106.35	N/A
7.04m					
153	1970.03	69364.7	1881	106.234	N/A
6.61m					
154	1950.37	5.95297e+08	1882	106.112	N/A
6.41m					
155	1939.50	123477	1878	106.099	N/A

6.23m
 156 1909.67   217390   1824   105.998   N/A
5.97m
 157 1879.78   48951.3   1841   105.954   N/A
6.11m
 158 1852.92   2.00151e+07   1828   105.831   N/A
5.57m
 159 1834.71   41082   1828   105.831   N/A
5.37m
 160 1817.06   74661.6   1832   105.797   N/A
5.10m
 161 1814.77   3860.34   1832   105.783   N/A
5.00m
 162 1808.57   62680.3   1842   105.664   N/A
4.96m
 163 1758.15   203506   1712   105.417   N/A
4.69m
 164 1690.86   92262   1712   105.394   N/A
4.39m
 165 1692.49   116450   1741   105.261   N/A
4.28m
 166 1727.47   66436.9   1739   105.171   N/A
4.22m
 167 1716.24   3.89336e+11   1741   105.141   N/A
4.23m
 168 1730.61   1.00493e+07   1750   105.092   N/A
4.06m
 169 1741.79   571328   1742   104.97   N/A
3.93m
 170 1733.52   1.78267e+07   1741   104.953   N/A
3.72m
 171 1730.60   502739   1954   104.847   N/A
3.58m
 172 1753.23   196115   1954   104.847   N/A
3.48m
 173 1755.67   5.67425e+08   2047   104.254   N/A
3.44m
 174 1757.01   82979   2047   104.254   N/A
3.40m
 175 1806.70   93743.3   2049   103.817   N/A
3.14m
 176 1954.89   35559.4   2022   103.736   N/A
3.22m
 177 2026.45   73924   2036   103.596   N/A
3.38m
 178 2044.62   87278.4   2048   103.544   N/A
3.16m
 179 2045.47   124714   2047   103.372   N/A
3.02m
 180 2031.76   130210   2134   103.226   N/A
2.83m
 181 2055.03   35068.6   2631   102.926   N/A
2.78m

```
 182  2066.12          72599.6     2633          102.919              N/A
2.62m
 183  2030.26           161098     2032           103.01              N/A
2.28m
 184  2020.91           136310     2076          102.829              N/A
2.29m
 185  2018.65          30982.9     2009          102.519              N/A
2.00m
 186  2003.83      6.01768e+08     2012          102.519              N/A
1.86m
 187  2022.74          79395.3     2527          102.476              N/A
1.78m
 188  2005.91          56386.1     2100          102.348              N/A
1.61m
 189  2016.43           115070     2184          102.345              N/A
1.44m
 190  2016.36          94111.4     2147          102.316              N/A
1.32m
 191  2018.53           173633     2083          102.054              N/A
1.21m
 192  2020.19           116259     2085          102.036              N/A
1.05m
 193  2036.41           134852     2081          101.931              N/A
53.90s
 194  2064.99          63033.3     2077          101.905              N/A
45.34s
 195  2083.19          33114.6     2082          101.271              N/A
36.69s
 196  2076.44           242556     2082          101.259              N/A
27.56s
 197  2075.79           192377     2082          101.247              N/A
18.45s
 198  2089.56      5.95726e+08     2101          101.067              N/A
9.32s
 199  2086.89          58925.5     2051          101.046              N/A
0.00s
```

[32]:
```
SymbolicRegressor(const_range=(-10, 10),
                  function_set=['add', 'sub', 'mul', 'div', 'sin'],
                  generations=200, init_depth=(4, 10), metric='mse',
                  population_size=500, random_state=0, stopping_criteria=0.01,
                  verbose=1)
```

[33]:
```
y_gp = est_gp.predict(np.array(xnum_test).reshape(-1, 1))
y_gp[:10]
```

[33]:
```
array([73.80469798, 74.62276246, 74.81765215, 74.88961676, 74.91224874,
       74.90617581, 74.87934757, 74.83554142, 74.77687615, 74.70473071])
```

[34]:
```
data2['predictions_GPLEARN'] = (train_size * [np.NAN]) + list(y_gp)
```

2.4.2. Визуализация

Построим график по тестовой выборке:

[37]:
```
fig, ax = pyplot.subplots(1, 1, sharex='col', sharey='row', figsize=(20,10))
fig.suptitle('Предсказания временного ряда (тестовая выборка)')
data2[train_size:].plot(ax=ax, legend=True)
pyplot.show()
```

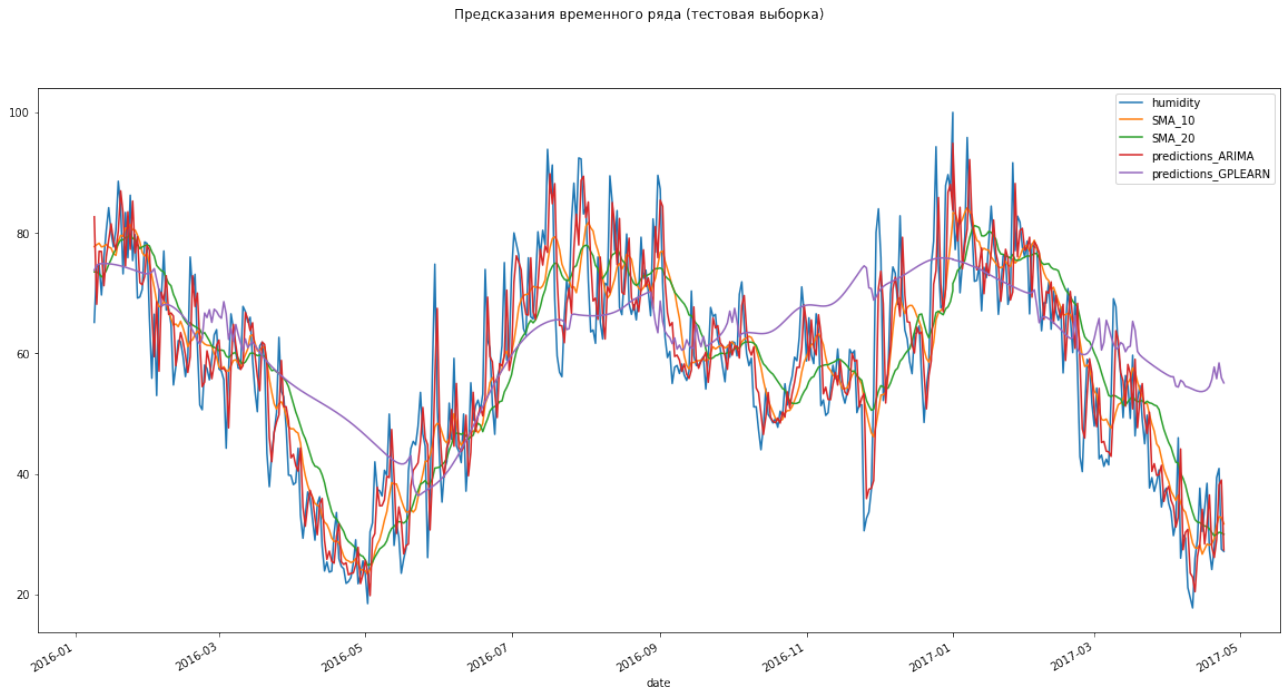

Визуально предсказания по методу сивольной регрессии менее точны, чем предсказания по ARIMA. Для повышения точности требуется настройка параметров метода, в частности увеличенное количество итераций цикла. Однако при этом сильно возрастут затраты времени.

2.4.3. Метрики

MAE и MSE:

[38]:
```
mean_squared_error(test, y_gp, squared=False)
```

[38]:
```
13.52324614284193
```

[39]:
```
mean_absolute_error(test, y_gp)
```

[39]:
```
10.607119049073066
```

2.5. Сранение качества моделей

Чем ближе значение MAE и MSE к нулю, тем лучше качество модели.

MAE для авторегрессионного метода ARIMA = 5.5, а для метода символьной регрессии = 10.6.

MSE для авторегрессионного метода ARIMA = 7.3, а для метода символьной регрессии = 13.5.

Качество модели для авторегрессионного метода ARIMA выше. Для выполенения ARIMA также требуется меньше времени.